

Инструкция для разметчика данных

Цель работы

Разметчик вручную проверяет и уточняет тактико-технические характеристики (ТТХ) беспилотных летательных аппаратов, полученные автоматически (агентный поиск, парсинг, синтетическая генерация), а также присваивает каждому БПЛА сегмент (кластер) для дальнейшего обучения моделей сегментации и многокритериального выбора.

Формат исходных данных

Файл CSV содержит колонки (пример):

- Model – название модели
- Weight_g – максимальная взлётная масса (г)
- Max_Speed_ms – максимальная скорость (м/с)
- Flight_Time_min – заявленное время полёта (мин)
- Actual_Flight_Time_min – реальное время (если известно)
- Range_km – дальность связи (км)
- Camera_MP – разрешение камеры (мегапиксели)
- Price_USD – цена в долларах
- *и другие, в зависимости от датасета.*

Важно: если поле Actual_Flight_Time_min отсутствует или содержит недостоверные значения, разметчик может его отредактировать на основе экспертной оценки или оставить пустым.

Как пользоваться приложением

1. Загрузка файла

- В боковой панели нажмите «Загрузить исходный CSV».
- Выберите файл (например, uav_dataset.csv или uav_dataset_with_real_data.csv).
- Приложение автоматически добавит служебные колонки: Segment, Comment, Verified.

2. Навигация

- Приложение показывает одну запись за раз – текущую неразмеченную модель.
- Слева отображаются все ТТХ, которые можно редактировать (числовые поля – с помощью стрелок, текстовые – вручную).
- Справа – поля для сегментации и комментария.

3. Редактирование ТТХ

- Сравните значения с официальными источниками (сайт производителя, технический паспорт).
- Если обнаружена ошибка (например, неверная масса или цена), исправьте её в левой колонке.
- Если данные отсутствуют – оставьте как есть или добавьте приблизительное значение, указав это в комментарии.

4. Присвоение сегмента (кластера)

- Выберите один из предустановленных сегментов, максимально соответствующий классу БПЛА:
 - *Легкий потребительский (<250г)* – мини-дроны, не требующие регистрации.
 - **Потребительский (250-900г)** – типичные квадрокоптеры для съёмки.
 - **Профессиональный (900-4000г)** – промышленная съёмка, инспекции.
 - **Промышленный (4-25кг)** – крупные коптеры, агродроны.
 - *Тяжелый промышленный (>25кг)* – грузовые платформы.
 - *FPV/гоночный* – скоростные дроны без стабилизации.
 - *Самолётного типа* – крылатые БПЛА.
 - *Гибридный/VTOL* – вертикальный взлёт и горизонтальный полёт.
 - *Другое* – если ни один не подходит (тогда укажите свой вариант в комментарии).

- В будущем сегменты могут быть расширены по согласованию с аналитиком.

5. Комментарий

- Заполняйте, если обнаружены расхождения, сомнительные значения или особая специфика (например, «реальное время полёта на 30% ниже заявленного из-за тяжёлой полезной нагрузки»).

6. Подтверждение

- Поставьте галочку «Данные проверены и верны», если вы уверены в корректности всех полей после редактирования.
- Нажмите кнопку «Сохранить разметку для этой модели».
- Приложение автоматически перейдёт к следующей неразмеченной записи.

7. Сохранение прогресса

- В любой момент можно нажать «Сохранить текущий прогресс» – все сделанные изменения запишутся в указанный CSV-файл.
- Рекомендуется сохранять прогресс каждые 10–20 записей, чтобы избежать потери данных.

8. Завершение работы

- Когда все строки будут размечены, приложение покажет сообщение об успехе.
- Финальный размеченный файл можно скачать кнопкой «Скачать CSV».

Рекомендации по качественной разметке

- Единообразие сегментации – используйте одни и те же правила для похожих моделей. Например, все дроны DJI серии Mini (масса ≤ 250 г) относите к «Легкий потребительский», независимо от цены.
- Проверяемые источники – при сомнениях сверяйтесь с официальными спецификациями производителя.

- Обоснованные правки – если вы меняете числовое значение, добавьте краткий комментарий (например, «исправлено по даташиту FCS»).
- Не оставляйте пустые сегменты – каждый БПЛА должен быть отнесён к какой-либо категории. Если ни один из предложенных не подходит, выберите «Другое» и опишите в комментарии.

Результат работы

После полной разметки вы получите CSV-файл, содержащий:

- исходные и исправленные ТТХ,
- колонку Segment с ручной сегментной меткой,
- колонку Comment с пояснениями,
- колонку Verified (флаг проверки).

Этот файл можно использовать для:

- обучения модели сегментации (кластеризация с учителем),
- верификации агентного поиска (оценка точности парсинга),
- построения аналитических дашбордов и отчётов.

Запуск приложения (для технического специалиста)

1. Установите Python 3.8+ и необходимые библиотеки:

pip install streamlit pandas numpy

2. Сохраните код приложения как `annotation_app.py`.

3. В терминале выполните:

streamlit run annotation_app.py

4. Откройте появившуюся ссылку (обычно <http://localhost:8501>) в браузере.

Что можно улучшить в будущем?

- Приложение может быть расширено: добавлен просмотр результатов агентного поиска (например, сравнение нескольких источников) или визуализация текущей сегментации в виде 3D-графика (Plotly).
- Размеченные сегменты можно подать на вход модели HDBSCAN для оценки качества автоматической кластеризации (метрики однородности, полноты).

- В будущем вместо ручного выбора сегментов можно предложить разметчику исправлять предложения ИИ (active learning).